



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
Facultad de Ciencias Naturales, Matemáticas y del Medio Ambiente.
Escuela de Química.



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
Facultad de Ciencias Naturales, Matemática y del Medio Ambiente
Escuela de Química

“Desarrollo de modelos QSAR basados en *machine learning* robustos e interpretables para la predicción de la permeabilidad intestinal pasiva en PAMPA”

Tesis para optar al Título de: **Ingeniero en Química**
y al grado de: **Licenciado en Ciencias de la Ingeniería Química**

Profesor Guía: Juan Alberto Castillo Garit
Doctor en Ciencias Farmacéuticas

Benjamín Andrés Vásquez Pérez

2026

NOTA OBTENIDA: _____

FIRMA Y TIMBRE DE LA AUTORIDAD RESPONSABLE

DEDICATORIA

A ustedes, que con amor y ejemplo formaron mi persona, gracias por estar siempre.

*A mis padres, mis hermanos: este logro no es solo mío,
es su triunfo.*

AGRADECIMIENTOS

En primer lugar, mi más sincero agradecimiento a mi profesor guía Juan, por su orientación, paciencia y rigor académico durante todo este proceso. Gracias por confiar en mis capacidades, por compartir su visión científica y guiarme no solo en el desarrollo de esta tesis, si no en mi formación como ingeniero.

A mis padres, por ser el soporte incondicional en cada etapa de mi vida. Gracias por sus sacrificios, por confiar en mí, inculcarme el valor del estudio y por no dejarme caer en los momentos mas difíciles. Todo lo que soy, es gracias al amor y la educación que ustedes me han entregado siempre.

A mis hermanos, Yerko, por confiar en mis capacidades, motivarme siempre a ser mejor persona y ser uno de mis ejemplos a seguir. Sebastián por siempre tirarme para arriba y decirme que soy el mejor en lo que hago. Y Tatiana que siempre esta para sacarme alguna sonrisa.

A mis amigos y compañeros, quienes hicieron más ameno este camino universitario. Gracias por motivarme a estudiar, por los momentos de distracción y darme el aliento cuando sentía que no me la podía.

Gracias a todos los que aportaron su granito de arena en este camino.

RESUMEN

La optimización de las propiedades farmacocinéticas, específicamente la absorción oral, constituye un desafío crítico en el desarrollo de nuevos fármacos. Si bien el ensayo de permeabilidad en membrana artificial paralela (PAMPA) se ha consolidado como un método eficaz para evaluar la difusión pasiva, su integración con herramientas computacionales permite acelerar significativamente la etapa de descubrimiento temprano. En el presente trabajo se desarrollaron y validaron modelos QSAR (*Quantitative Structure-Activity Relationship*) basados en algoritmos de Machine Learning para la predicción de la permeabilidad intestinal pasiva. Se recopiló y curó una base de datos diversa compuesta por compuestos con valores experimentales reportados, garantizando la fiabilidad del *endpoint* biológico. Tras el cálculo de los descriptores moleculares y la selección de las mejores variables, se entrenaron diversos modelos de clasificación, destacando el obtenido con la técnica *Random Forest* como mejor opción por su equilibrio entre estabilidad y predicción. El modelo seleccionado además de definirle el dominio de aplicación, fue sometido a una estrategia de validación jerárquica en cuatro etapas: (1) Una validación cruzada interna ($k=5$) que arrojó un AUC de 0.8; (2) Una validación externa rigurosa con una base de datos independiente de 486 compuestos (no utilizados en el entrenamiento); (3) Un cribado simulado aplicado a una serie reciente de cinco moléculas experimentales, confirmando la capacidad del modelo para clasificar nuevas entidades moleculares; y (4) Un cribado virtual sobre la base de datos DrugBank, logrando filtrar e identificar candidatos con perfiles farmacocinéticos favorables. Se concluye que la herramienta desarrollada es robusta y generalizable, permitiendo priorizar compuestos con favorables perfiles de permeabilidad y mayor probabilidad para convertirse en fármaco permitiendo así reducir costos y ensayos experimentales.

ABSTRACT

The optimization of pharmacokinetic properties, specifically oral absorption, constitutes a critical challenge in the development of new drugs. While the Parallel artificial membrane permeability assay (PAMPA) has been established as an effective method for evaluating passive diffusion, its integration with computational tools allows for a significant acceleration of the early drug discovery stage. In the present study, Quantitative Structure-Activity Relationship (QSAR) models based on Machine Learning algorithms were developed and validated for the prediction of passive intestinal permeability. A diverse database comprising compounds with reported experimental values was collected and curated, ensuring the reliability of the biological endpoint. Following the calculation of molecular descriptors and feature selection, various classification models were trained, with the Random Forest algorithm emerging as the optimal choice due to its balance between stability and predictive performance. In addition to defining its domain of applicability, the selected model underwent a rigorous four-stage hierarchical validation strategy: (1) Internal cross-validation ($k=5$), yielding an AUC of 0.80; (2) Rigorous external validation using an independent dataset of 486 compounds (excluded from the training set); (3) Simulated screening applied to a recent series of five experimental molecules, confirming the model's capacity to classify new molecular entities; and (4) Virtual screening on the DrugBank database, successfully filtering and identifying candidates with a favorable pharmacokinetic profiles. It is concluded that the developed tool is robust and generalizable, enabling the prioritization of compounds with favorable permeability profiles and higher drug development potential, thereby reducing experimental testing and associated costs.

ÍNDICE GENERAL

Contenido

Capítulo 1: Introducción	1
1.1 Hipótesis	3
1.2 OBJETIVOS	3
1.2.1 Objetivo General.....	3
1.2.2 Objetivos Específicos	3
Capítulo 2: Marco teórico.....	4
2.1 Contexto actual de la industria farmacéutica.....	4
2.1 El rol de las propiedades ADME	5
2.2 Absorción intestinal y biodisponibilidad oral.....	6
2.3 Mecanismos de transporte a través de Membranas	6
2.4. Metodologías experimentales para la evaluación de la permeabilidad.	7
2.4.1 Modelo celular Caco-2	8
2.4.2 Modelo celular MDCK (Madin-Darby canine kidney)	8
2.4.3 Modelo de células caliciformes (HT29-MTX).....	9
2.5. Modelos <i>in-vivo</i>	9
2.5.1 Perfusión intestinal in situ de rata (SPIP)	9
2.5.2 Correlación rata-humano	9
2.6 Ensayo de Permeabilidad en membrana artificial paralela (PAMPA)	9
2.6.2 Justificación del uso de PAMPA para modelado QSAR.....	10
2.7 Fundamentos teóricos de los modelos QSAR	11
2.7.1 Representación lineal (SMILES).....	12
2.7.2 Descriptores moleculares.....	12
2.7.3 Curación y estandarización de datos (<i>Data Curation</i>)	14
2.7.4 <i>Machine Learning</i> aplicado a los modelos QSAR.	14
2.7.4.1 Regresión logística	14
2.7.4.2 Árbol de decisión.....	15
2.7.4.3 Random Forest.....	15
Capítulo 3: Materiales y métodos	17
3.1 Conjunto de datos (<i>Dataset</i>).....	17

3.2 Curación y cálculo de descriptores	17
3.3 Análisis exploratorio de datos (EDA) y preselección	18
3.3.1 Evaluación de integridad y distribución.	18
3.3.2 Análisis de colinealidad.....	18
3.3.3 Preselección mediante eliminación recursiva (RFE).....	18
3.3.4 Selección de atributos (<i>Feature selection</i>)	19
3.4 Desarrollo del modelo predictivo	19
3.4.1 Configuración y optimización	19
3.4.2 Manejo del desbalance de clases	19
3.5 Métricas de clasificación	19
3.5.1 Matriz de confusión	19
Capítulo 4: Resultados y discusiones	22
4.1 Visualización del Dataset.	22
4.2 Análisis de relevancia de atributos.	22
4.3 Análisis de Mann-Whitney	23
4.4 Análisis de correlación de Spearman.....	24
4.4 Recursive Feature Elimination (RFE)	25
4.5 Selección de Características	25
4.5.1 Metodología de selección automatizada en WEKA	26
4.5.2 Análisis de Consenso.....	26
4.6 Validación del modelo.....	26
4.6.1 Validación Cruzada	29
4.6.2 Validación externa.....	29
4.7 Comparación con modelos QSAR reportados en la literatura.....	30
4.8 Cribado de bases de datos de interés	33
4.8.1 Cribado simulado.....	33
4.8.2 Cribado Virtual	34
Capítulo 5: Conclusiones.....	37
Capítulo 6: Referencias	39

ÍNDICE DE FIGURAS

Figura 1. Costo desde el descubrimiento hasta el lanzamiento de un fármaco en la última década, adaptado del reporte de Deloitte centre for health solutions [13].	4
Figura 2. Representación simplificada de los mecanismos de transporte que tienen lugar en el epitelio intestinal	7
Figura 3. Representación gráfica del ensayo PAMPA.	10
Figura 4. Principios regulatorios establecidos por la OECD para el desarrollo de modelos QSAR.	12
Figura 5. Representación gráfica de una matriz de confusión. ¡Error! Marcador no definido.	
Figura 6. Distribución de clases en el conjunto de entrenamiento.¡Error! Marcador no definido.	
Figura 7. Análisis de relevancia de los descriptores.	23
Figura 8. Descriptores significativos dentro de los valores p-value esperados.	23
Figura 9. Análisis de correlación de Spearman (Top 20). Se descartan el par de variables que superan el umbral establecido.	24
Figura 10. Top 30 variables importantes según importancia de Gini.	25
Figura 11. Curvas ROC para el conjunto de entrenamiento y el conjunto de validación interna.	28
Figura 12. Matriz de confusión para el conjunto de validación externa.	30
Figura 13. Ejemplos de Scaffolds encontrados.	36

ÍNDICE DE TABLAS

Tabla 1. Descriptores moleculares empleados en el modelo <i>Random Forest</i> .	27
Tabla 2. Parámetros estadísticos alcanzados por el modelo.	28
Tabla 3. Resultados de la validación cruzada para el modelo de clasificación.	29
Tabla 4. Tabla comparativa modelos QSAR reportados en la literatura.	32
Tabla 5. Resultados del Cribado simulado.	34
Tabla 6. Top 10 compuestos identificados en el Cribado Virtual	35



Capítulo 1: Introducción

El diseño racional de fármacos se enfrenta a un paradigma de productividad decreciente, donde la inversión en investigación y desarrollo (I+D) ha crecido de forma desproporcionada en comparación con el número de nuevas entidades moleculares aprobadas. Estudios de referencia sitúan el costo capitalizado para llevar un nuevo fármaco al mercado en más de 2.6 mil millones de dólares [1] una cifra monumental agravada por tasas de fallos extremadamente altas. Análisis históricos demuestran que, en promedio, solo una de cada nueve moléculas que entran en la etapa de los ensayos clínicos llega a ser aprobada [2]. Este escenario de altos costos y baja probabilidad de éxito exige un cambio de paradigma hacia estrategias de "fallar pronto y fallar barato" [3], donde la optimización temprana de las propiedades del fármaco es un imperativo estratégico para reducir la deserción en etapas tardías y por tanto más costosas del desarrollo de un nuevo fármaco.

En este contexto, las propiedades ADME (Absorción, Distribución, Metabolismo y Excreción) han emergido como factores determinantes del éxito o fracaso de un candidato. Por ello, la optimización temprana de las propiedades ADME es una de las estrategias más efectivas para disminuir la tasa de fracaso [4]. Históricamente, una farmacocinética y biodisponibilidad deficientes eran la causa principal del fracaso de los candidatos a fármacos, representando aproximadamente el 40% de los abandonos en la fase clínica. Sin embargo, la integración proactiva del cribado de propiedades ADME en las fases tempranas del descubrimiento ha transformado drásticamente este panorama. La industria ha logrado reducir esta tasa de fracaso a cerca del 10%, demostrando que la optimización temprana de las propiedades ADME es una de las estrategias más efectivas para reducir la tasa de fracaso [2], [4]. Dentro del perfil ADME, la absorción es un factor fundamental para los fármacos administrados por vía oral; la cual es la vía más deseada sobre todo para tratamientos crónicos debido a su comodidad y facilidad para que los pacientes se adhieran al tratamiento durante un tiempo prolongado [5]

La permeabilidad a través de las membranas biológicas es el factor fundamental que gobierna la absorción de los fármacos administrados por vía oral determinando la absorción y biodisponibilidad de una molécula [6]. Una permeabilidad deficiente puede limitar drásticamente la cantidad de fármaco que ingresa al organismo y, por ende, a la circulación sistémica; la cuál es la encargada de transportarla hasta su sitio de acción, llevando al fracaso terapéutico. La permeabilidad intestinal no es más que el paso de un fármaco a través de la membrana del epitelio intestinal y desde el punto de vista farmacológico es la más importante. Esta consiste en el paso de una molécula desde el lumen intestinal hacia la circulación sistémica

y está mediado por una compleja interacción de mecanismos de transporte. Los principales mecanismos son: i) la difusión pasiva, que es un proceso impulsado por gradiente de concentración que no requiere energía y se subdivide en la ruta transcelular (a través de la membrana lipídica) y la paracelular (a través de las uniones intercelulares); ii) el transporte activo mediado por transportadores de captación; y iii) el eflujo activo, mediado por bombas como la Glicoproteína-P (P-gp), que expulsan activamente los fármacos de vuelta al lumen, limitando su absorción [7], [8].

Para evaluar la permeabilidad intestinal en fases tempranas, se han desarrollado varios ensayos *in vitro* de alto rendimiento que permiten modelar este complejo proceso. El modelo *in vitro* más utilizado es la línea celular de carcinoma de colon humano tipo 2 (Caco-2), que mide el transporte del fármaco a través de la membrana celular y la medición de las rutas de transporte paralelas, pasivas y activas [9]. El ensayo con células Caco-2 si bien es considerado el estándar de oro para predecir la absorción intestinal, su mayor complejidad, costo y menor rendimiento justifican el desarrollo y aplicación de modelos alternativos como el ensayo de Permeabilidad en Membrana Artificial Paralela (PAMPA), [10]. Por su parte el ensayo de PAMPA es una alternativa altamente eficiente pues emplea una membrana artificial impregnada de lípidos para simular la barrera intestinal, aislando específicamente el mecanismo de difusión pasiva [11]. Sus ventajas clave son: su bajo costo, su alta velocidad y su excelente reproducibilidad y automatización sencilla, factores que lo posicionan como una herramienta ideal para el cribado primario y la optimización de la permeabilidad intrínseca en el descubrimiento de fármacos [3], [12].

Para acelerar aún más el ciclo de diseño-síntesis-prueba, los modelos computacionales *in silico* ofrecen un método predictivo aún más rápido y rentable. Las Relaciones Cuantitativas Estructura-Actividad (QSAR), potenciadas por técnicas de aprendizaje automático de máquinas (ML por sus siglas en inglés de *Machine Learning*), se basan en un principio fundamental: las propiedades biológicas o fisicoquímicas de una molécula son una función de su estructura química. Mediante la correlación de descriptores moleculares numéricos con una propiedad experimental, como la permeabilidad medida en el ensayo PAMPA, es posible construir modelos predictivos que nos permitan evaluar *a priori* la absorción que tendrían los nuevos compuestos.

A pesar de la existencia de varios modelos QSAR para predecir la permeabilidad de compuestos de interés, persiste aún una brecha significativa en el campo. Muchos de los modelos publicados anteriormente se basan en conjuntos de datos pequeños u obtenidos de fuentes heterogéneas, lo que limita su generalización. Además, con frecuencia carecen de una validación estadística rigurosa o funcionan como "cajas negras", ofreciendo predicciones sin proporcionar una comprensión clara de las relaciones estructura-propiedad subyacentes [4], [7]. Esta falta de interpretabilidad impide su uso efectivo en el diseño racional de fármacos. Por lo tanto, este proyecto entregará un activo de doble valor: un motor predictivo de alta precisión para mitigar el riesgo de los candidatos en fases tempranas y un marco de trabajo interpretable que genera inteligencia química aplicable, permitiendo directamente a los químicos medicinales diseñar

moléculas superiores desde sus principios fundamentales. A continuación, se detallan los objetivos específicos del proyecto.

1.1 Hipótesis

Es posible desarrollar modelos QSAR basados en técnicas de *Machine Learning* que sean capaces de predecir la permeabilidad intestinal pasiva mediante el ensayo PAMPA con desempeño estadístico destacado y mejorando el nivel de interpretabilidad.

1.2 OBJETIVOS

1.2.1 Objetivo General

Desarrollar y validar modelos QSAR interpretables y generalizables que permitan una mejor predicción de la permeabilidad pasiva de compuestos, empleando técnicas de *machine learning*.

1.2.2 Objetivos Específicos

- Recopilar y curar una base de datos, diversa y de alta calidad, de compuestos con reportes de valores experimentales de permeabilidad en PAMPA, asegurando la consistencia y fiabilidad del *endpoint* biológico.
- Implementar y construir modelos QSAR de permeabilidad intestinal pasiva basados en técnicas de *machine learning* (ML)
- Validar estadísticamente los modelos QSAR de acuerdo con los principios establecidos por la Organización para la Cooperación y el Desarrollo Económicos (OCDE)
- Evaluar el desempeño prospectivo de los modelos QSAR mediante su aplicación en un cribado simulado y virtual de compuestos de interés.



Capítulo 2: Marco teórico

2.1 Contexto actual de la industria farmacéutica

El descubrimiento y desarrollo de fármacos se caracteriza por su alta complejidad técnica, largos tiempos de ejecución y un riesgo financiero significativo. Históricamente, se ha observado una tendencia de productividad decreciente conocida como la “Ley de Eroom” (opuesto a Moore), donde el costo de introducir un fármaco al mercado aumenta exponencialmente a pesar de los avances tecnológicos.

Si bien estudios estiman que el costo capitalizado de desarrollo es aproximadamente 2,6 mil millones de dólares [1], análisis más recientes de [13] sitúan la inversión promedio por activo en cerca de 2,3 mil millones de dólares, con una tasa interna de retorno que, aunque ha mostrado una leve recuperación impulsada por fármacos para la obesidad (GLP-1), sigue siendo un desafío crítico para la sustentabilidad de la industria (ver Figura 1)



Figura 1. Costo desde el descubrimiento hasta el lanzamiento de un fármaco en la última década, adaptado del reporte de Deloitte centre for health solutions [13].

A este escenario económico se suma una tasa de deserción (*attrition rate*) alarmante. Mientras que a principios de los años 2000 se estimaba que una de cada nueve moléculas que ingresaban a ensayos clínicos lograba ser aprobada [2] datos recientes indican que la tasa de éxito clínico ha descendido a un mínimo histórico del 6.7% para nuevos candidatos en fase I. Estos datos evidencian la urgencia de implementar estrategias de “fallar pronto, fallar barato”, priorizando la identificación temprana de compuestos con perfiles de seguridad y eficacia antes de incurrir en los altos costos de las fases clínicas avanzadas [14].

2.1 El rol de las propiedades ADME

El perfil farmacocinético de una molécula determina su destino dentro del organismo y es evaluado a través de las propiedades ADME, la evaluación conjunta de estos parámetros es crítica, ya que la molécula puede tener una actividad biológica *in vitro* excepcional (alta afinidad por el target), pero carecer de utilidad terapéutica si no logra alcanzar su sitio de acción en la concentración adecuada y durante el tiempo necesario.

A continuación, se describen los componentes de este perfil:

Absorción (A): Es el proceso mediante el cual el fármaco se traslada desde el sitio de administración hasta la circulación sistémica. Para la administración oral (la vía preferida en la industria), este paso depende intrínsecamente de la solubilidad del compuesto en los fluidos gastrointestinales y de su permeabilidad a través de las barreras biológicas, como el epitelio intestinal.

Distribución (D): Una vez en el torrente sanguíneo, el fármaco se dispersa reversiblemente hacia los distintos tejidos y fluidos del organismo (intersticial e intracelular). Este proceso está gobernado por factores fisicoquímicos como la lipofilidad y la unión a proteínas plasmáticas, así como la capacidad de atravesar barreras especializadas (como la barrera hematoencefálica). Un volumen de distribución adecuado asegura que el fármaco llegue al tejido diana donde debe ejercer su efecto.

Metabolismo (M): Comprende el conjunto de reacciones de biotransformación química, llevadas a cabo principalmente en el hígado por enzimas como las del complejo Citocromo (CYP). El objetivo biológico es convertir compuestos lipofílicos en metabolitos más polares para facilitar su eliminación. En el diseño de fármacos, se busca optimizar la estabilidad metabólica para evitar que el fármaco sea degradado antes de actuar (efecto de primer paso) o que genere metabolitos tóxicos.

Excreción (E): Es el proceso final de eliminación del fármaco y sus metabolitos del organismo, realizado mayoritariamente a través de las vías renal (orina) y biliar (heces). La velocidad de

excreción determina la vida media del fármaco y, por ende, la frecuencia con la que debe ser administrado al paciente (dosificación).

Históricamente, las deficiencias en estas propiedades fueron la causa principal de fallo en el desarrollo de fármacos, representando casi el 40% de la deserción en la década de 1990. Gracias a la implementación masiva de ensayos *in vitro* e *in silico* en etapas tempranas, la industria logro reducir significativamente los fallos debidos a la farmacocinética. Sin embargo, actualmente, la toxicidad imprevista y la falta de eficacia clínica siguen siendo las causas dominantes del fracaso [7]. En este contexto, la predicción precisa de la permeabilidad y la biodisponibilidad no solo busca asegurar que el fármaco llegue a su diana terapéutica, sino también prever posibles acumulaciones toxicas o interacciones metabólicas no deseadas, consolidándose como un pilar fundamental para el diseño racional de fármacos asistidos por computadora (CADD).

2.2 Absorción intestinal y biodisponibilidad oral

La vía oral es la ruta de administración preferida para la mayoría de los fármacos debido a su conveniencia, bajo costo y alta adherencia por parte del paciente. Para que un fármaco administrado sea eficaz, debe superar una serie de barreras fisiológicas, siendo la absorción intestinal el paso limitante más crítico. La absorción se define como el movimiento del fármaco desde el sitio de administración hasta la circulación sistémica. Este proceso ocurre mayoritariamente en el intestino delgado, donde la gran superficie de vellosidades y microvellosidades facilita el paso de los xenobióticos. La capacidad de una molécula para atravesar el epitelio intestinal depende intrínsecamente de sus propiedades fisicoquímicas, como la lipofilia, el tamaño molecular, el grado de ionización y de su interacción con la membrana biológica [3], [8].

2.3 Mecanismos de transporte a través de Membranas

El epitelio intestinal actúa como una barrera selectiva que regula la absorción de xenobióticos. Para alcanzar la circulación sistémica, los fármacos deben atravesar esta barrera biológica (ver Figura 2) mediante procesos que pueden clasificarse fundamentalmente en dos grandes categorías según su requerimiento energético y cinética: Transporte pasivo y transporte activo [15].

1. Transporte Pasivo: Este mecanismo se caracteriza por ocurrir a favor de un gradiente de concentración (desde una zona alta de concentración a una baja) y no requiere gasto de energía metabólica (ATP). Es el proceso de absorción predominante para aproximadamente el 90% de los fármacos comerciales [16]. Dentro de esta categoría se distinguen dos vías principales:
2. Difusión transcelular: El fármaco atraviesa directamente la bicapa lipídica de las células epiteliales. Su eficiencia depende de la lipofilidad de la molécula y es el mecanismo específico que mimetiza el ensayo PAMPA utilizando en esta investigación [17].

3. Difusión paracelular: Implica el paso de moléculas pequeñas e hidrofílicas a través de las uniones estrechas (*tight junctions*) entre las células. Esta vía está limitada exclusivamente a moléculas pequeñas (<200 Da) e hidrófilas [18]
4. Transporte Activo: A diferencia del transporte pasivo, este mecanismo requiere el aporte de energía celular para mover las moléculas en contra de su gradiente electroquímico. Este proceso es mediado por proteínas transportadoras específicas situadas en la membrana (como glicoproteína-P o transportadores de solutos), lo que implica que es un fenómeno saturable y susceptible a inhibición competitiva [11] Si bien es crucial para la absorción de nutrientes y análogos estructurales, el transporte activo representa una vía minoritaria para las nuevas entidades moleculares (NEM) en etapas tempranas de descubrimiento




Figura 2. Representación simplificada de los mecanismos de transporte que tienen lugar en el epitelio intestinal

Dado que los modelos basados en membranas artificiales como PAMPA se centran exclusivamente en la difusión pasiva, su uso se justifica bajo la premisa de que, para la gran mayoría de las nuevas entidades químicas en etapas de screening, la lipofilicidad y la permeabilidad pasiva siguen siendo los mejores predictores iniciales de la fracción absorbida en humanos [11]. También la difusión pasiva es la ruta mayoritaria de absorción, por lo que el uso de modelos como PAMPA (que aíslan este mecanismo eliminando interferencia de transportadores activos) resulta una estrategia altamente predictiva y costo-efectiva para el cribado inicial de la permeabilidad intestinal [19]

2.4. Metodologías experimentales para la evaluación de la permeabilidad.

Para la predicción efectiva de la absorción oral en humanos, la industria farmacéutica ha desarrollado diversos modelos sustitutos (*surrogate models*) que permiten estimar la permeabilidad intestinal sin recurrir a estudios *in vivo* en etapas tempranas. Estos modelos se dividen principalmente en basados en cultivos celulares y basados en membranas artificiales

2.4.1 Modelo celular Caco-2

La línea celular Caco-2, derivada del carcinoma colorrectal humano, se ha consolidado como el estándar de referencia para la predicción de la absorción intestinal *in vitro*. A pesar de su origen colónico, estas células tienen la capacidad de diferenciarse espontáneamente en monocapas de enterocitos polarizados que exhiben las características morfológicas y funcionales del intestino delgado, incluyendo la formación de microvellosidades y *tight junctions* bien desarrolladas [10]

La principal ventaja del modelo Caco-2 reside en su complejidad biológica: permite evaluar no solo el transporte pasivo (transcelular y paracelular), sino también el transporte activo mediado por portadores y los mecanismos de eflujo, además de considerar el metabolismo presistémico por enzimas de fase I y II expresadas en el citosol.

Sin embargo, este modelo presenta limitaciones significativas para el cribado de alto rendimiento (HTS):

1. Tiempo y costo: Requiere un periodo de cultivo de 21 a 24 días para alcanzar la diferenciación completa.
2. Variabilidad: Existen discrepancias interlaboratorios notables debido a diferencias en el número de pases y las condiciones de cultivo.
3. Complejidad de interpretación: Al medir una permeabilidad compuesta (suma de pasiva + activa +/- eflujo), resulta complejo disociar que fracción del transporte corresponde a las propiedades fisicoquímicas intrínsecas de la molécula, representa “ruido biológico” al intentar desarrollar modelos QSAR [8]

2.4.2 Modelo celular MDCK (Madin-Darby canine kidney)

Las células MDCK, derivadas del epitelio renal canino, se han consolidado como una alternativa eficiente para el cribado de permeabilidad con un *high-throughput screening*. A diferencia de Caco-2, estas requieren un tiempo de diferenciación significativamente menor (entre 3 a 5 días), lo que permite una generación de grandes volúmenes de entrenamiento en los algoritmos de *Machine Learning* [20]

Desde una perspectiva biofarmacéutica, las monocapas MDCK desarrollan *tight junctions* con una resistencia eléctrica transepitelial (TEER) comparable o superior a la de Caco-2, lo que las convierte en un modelo ideal para simular no solo la barrera intestinal, sino también la barrera hematoencefálica (o por sus siglas en inglés, *blood-brain barrier* (BBB)). Distintos estudios han demostrado una alta correlación ($R^2 > 0.8$) entre los coeficientes de permeabilidad aparente (Papp) obtenidos en MDCK y los valores de absorción en humanos para compuestos que transportan pasivamente [21]. Además, algunas variantes transfectadas como MDCK-MDR1 permiten evaluar específicamente el impacto de los transportadores de *efflux* (glicoproteína-P) en la biodisponibilidad de nuevos fármacos.

2.4.3 Modelo de células caliciformes (HT29-MTX)

En el orden de mimetizar la complejidad fisiológica del intestino humano, es necesario considerar la barrera de difusión que es impuesta por la capa de mucus, la cual se ausenta en los monocultivos tradicionales de Caco-2. La línea celular HT29-MTX consiste en subclones de adenocarcinoma de colon HT-29 adaptados mediante tratamiento con metotrexato (MTX). Estas células se diferencian en un fenotipo secretor de mucina (células caliciformes o *globet cells*), produciendo principalmente mucinas MUC5AC y MUC2, las cuales forman una red de gel viscoelástico sobre el epitelio [22].

2.5. Modelos *in-vivo*

Aunque los modelos *in vitro* son herramientas indispensables para el cribado inicial, carecen de la complejidad sistémica inherente a un organismo vivo (flujo sanguíneo, innervación, motilidad, gradientes de pH, etc.). Por ello, la validación final de los modelados QSAR de permeabilidad suele contrastarse con datos obtenidos de modelos animales *in vivo* o *in situ*, que representan el estándar preclínico antes de los ensayos en humanos.

2.5.1 Perfusión intestinal in situ de rata (SPIP)

El modelo de perfusión intestinal de paso único (por sus siglas en inglés, *Single-pass intestinal perfusion*) en rata es el método más robusto para determinar la permeabilidad efectiva (P_{eff}) en un entorno fisiológico preservado. A diferencia de los métodos estáticos, el SPIP mantiene el suministro sanguíneo mesentérico intacto, lo que asegura los mecanismos de transporte activo y pasivo funcionen bajo condiciones hemodinámicas reales (Fagerholm et al., 1996).

2.5.2 Correlación rata-humano

La justificación de utilizar datos de rata como “proxy” o variable objetivo (*target*) en modelos de *machine learning* radica en la alta correlación interespecie existente. Estudios clásicos de biofarmacia han demostrado una correlación lineal significativa ($R^2 > 0.8$) entre permeabilidad yeyunal de rata y la fracción absorbida en humanos ($F_{a, human}$) para fármacos transportados pasivamente [23]. Sin embargo, para fármacos que son sustratos de transportadores específicos como (P-gp o PEPT1), esta correlación puede desviarse debido a las diferencias en la expresión de transportadores entre especies. Por tanto, en el contexto de modelación QSAR, los datos *in vivo* de rata se utilizan frecuentemente para construir modelos de “correlación fisiológica” que ajustan las predicciones iniciales de Caco-2 [24].

2.6 Ensayo de Permeabilidad en membrana artificial paralela (PAMPA)

En respuesta las limitaciones de los modelos celulares antes expuestos, Kansy et al [17] introdujeron el ensayo PAMPA. Esta metodología se fundamenta en un sistema de “sándwich” de 96 pozos, compuesto por una placa donadora (que contiene el fármaco) y una placa aceptora, separadas por una membrana de filtro hidrofóbico impregnada con una solución lipídica. La permeabilidad se calcula midiendo la cantidad de fármaco que logra cruzar esta barrera lipídica tras un tiempo de incubación (ver Figura 3).

A diferencia de la técnica de Caco-2, la de PAMPA evalúa exclusivamente el transporte pasivo transcelular. Dado que aproximadamente el 80-90% de los fármacos comerciales se absorben principalmente por difusión pasiva, PAMPA ofrece una estimación robusta de la fracción absorbida para la gran mayoría de las nuevas entidades químicas (NEM)[11]




Figura 3. Representación gráfica del ensayo PAMPA.

Evolución y Metodología *Double-Sink*

El ensayo PAMPA ha evolucionado desde su concepción original para mejorar su correlación con datos humanos. Una de las variantes más robustas es el *Double-Sink* PAMPA (DS-PAMPA), desarrollado por [3]. Esta variante incorpora un "sumidero" químico (generalmente surfactantes o proteínas) en el compartimento aceptor para simular el gradiente de concentración que mantiene el flujo sanguíneo *in vivo* y reducir la capa de agua no agitada (*Unstirred Water Layer*, UWL), un artefacto experimental que históricamente subestimaba la permeabilidad de compuestos altamente lipofílicos.

2.6.2 Justificación del uso de PAMPA para modelado QSAR

La elección de datos PAMPA como base para el desarrollo de los modelos de *Machine Learning* propuestos en esta tesis se justifica en tres pilares fundamentales:

1. Limpieza del dato: Al eliminar los componentes activos y metabólicos, PAMPA aísla la interacción fisicoquímica entre el soluto y la bicapa lipídica. Esto genera datos de permeabilidad pasiva intrínseca (P_e) que correlacionan directamente con descriptores moleculares estructurales (lipofilicidad, tamaño, aceptores/donadores de H) facilitando el entrenamiento de modelos predictivos más interpretables [25]
2. Volumen y homogeneidad: La naturaleza de alto rendimiento y automatización de PAMPA ha permitido la generación de grandes bases de datos públicas y privadas con

protocolos estandarizados, superando los problemas de reproducibilidad que afectan a los conjuntos de datos de Caco-2 públicos.

3. Relevancia actual: Investigaciones recientes sugieren que, para propósitos de benchmarking computacional, los datos de permeabilidad pasiva bien curados (como los de PAMPA) son preferibles para entrenar algoritmos iniciales, ya que permiten definir el comportamiento base de la molécula antes de añadir capas de complejidad biológica [8].

2.7 Fundamentos teóricos de los modelos QSAR

La premisa central de los modelos QSAR se basa en el axioma de que la estructura molecular de un compuesto químico contiene la información necesaria para determinar sus propiedades fisicoquímicas y biológicas. Por lo tanto, moléculas con estructuras similares deberían exhibir actividades o propiedades similares (Principio de similitud)

Matemáticamente, un modelo QSAR busca establecer una función f tal que:

$$P = f(D)$$

Donde P es la propiedad de interés (en este caso, la permeabilidad, LogP) y D es un vector de descriptores moleculares (DMs) que representan numéricamente la estructura química. El objetivo de la tesis es encontrar la función f optima utilizando algoritmos de Machine Learning, superando las limitaciones de la linealidad de los enfoques clásicos de Hansch y Free-Wilson [26]

Para que un modelo QSAR sea aceptado a nivel regulatorio y considerado científicamente válido para la predicción de propiedades fisicoquímicas y biológicas, debe adherirse a los cinco principios establecidos por la Organización para la Cooperación y el Desarrollo Económicos (OCDE) en 2004 [27]. (ver Figura 4). Estos criterios aseguran la transparencia y reproducibilidad del modelo:

1. Un punto final (*endpoint*) definido: La propiedad que se intenta predecir (en este caso, la permeabilidad efectiva en PAMPA, $\log P_e$) debe estar claramente identificada y medirse bajo condiciones experimentales consistentes.
2. Un algoritmo inequívoco: La metodología matemática utilizada para generar el modelo (por ejemplo: Random Forest, Regresión lineal) debe ser transparente, permitiendo a cualquier investigador pueda reproducir las predicciones utilizando los mismos datos y parámetros.
3. Un dominio de aplicación definido: Se deben establecer los límites del espacio químico dentro del cual el modelo realiza predicciones confiables, advirtiendo sobre la incertidumbre al extrapolar a compuestos estructuralmente distintos a los del conjunto de entrenamiento.
4. Medidas apropiadas de bondad de ajuste, robustez y predictividad: El modelo debe ser evaluado estadísticamente tanto internamente (mediante validación cruzada) como

externamente (utilizando un conjunto de prueba independiente), demostrando su capacidad para generalizar.

5. Una interpretación mecanística (si es posible): Se debe ofrecer una explicación fisicoquímica de las variables seleccionadas, justificando causalmente por que ciertos descriptores moleculares correlacionan con la actividad biológica observada.



Figura 4. Principios regulatorios establecidos por la OECD para el desarrollo de modelos QSAR.

2.7.1 Representación lineal (SMILES)

La notación SMILES (*Simplified Molecular Input Entry System*, por sus siglas en inglés) es el estándar de manual para la representación de estructuras químicas en formato de texto ASCII. Esta notación permite describir la conectividad atómica, la ramificación y la estereoquímica de una molécula en una cadena de caracteres lineal. Para fines de modelado computacional, es crítico utilizar SMILES canónicos, un algoritmo que garantiza que una estructura química única genere siempre la misma cadena de texto, independientemente de cómo se haya dibujado originalmente [28].

2.7.2 Descriptores moleculares

Los DMs son términos que caracterizan un aspecto específico de una molécula y contienen información estructural de las moléculas bajo estudio. La naturaleza de los descriptores depende de cual haya sido el proceder utilizado para la definición de estos, pudiendo tener en cuenta rasgos topológicos (2D), geométricos (3D), y electrónicos de la molécula. Algunos de estos descriptores, sin embargo, tienen información de propiedades fisicoquímicas, tales como la mayoría de las constantes sustituyentes, hidrofóbicas y estéricas [29].

En otros términos, estos números brindan un espectro más amplio sobre la interpretación de las propiedades moleculares y también son capaces de tomar parte en un modelo para la predicción de propiedades moleculares de interés. En este sentido, si la interpretación del DM es débil, o

carente completamente de significado, aun el mismo puede estar fuertemente correlacionado con alguna propiedad molecular, lo cual es de gran utilidad para la generación de modelos con alta capacidad predictiva. Por otro lado, los descriptores con un bajo poder predictivo se pueden retener en los modelos cuando están bien fundados teóricamente y son, por ende, interpretables debido a su capacidad de codificar la información química estructural. De acuerdo con la naturaleza en su definición y a la complejidad de los rasgos moleculares estructurales que codifican, los DMs se clasifican de forma general según las dimensiones que abarcan: Descriptores Constitucionales (DMs-0D), Descriptores Unidimensionales (DMs-1D), Descriptores Bidimensionales, Invariantes de Grafos (DMs-2D), Descriptores Tridimensionales (DMs-3D) y Descriptores tetradimensionales (DMs-4D) [29]

- Descriptores 0D: Son descriptores que se obtienen directamente de la formula molecular y son independientes de cualquier conocimiento sobre la estructura molecular, por ejemplo, el número de átomos(A), el peso molecular (MW), conteo de átomos-tipo (Nx) o cualquier función de las propiedades atómicas [19]. Son computacionalmente económicos y esenciales para definir el “dominio de aplicabilidad” del modelo [29].
- Descriptores 1D: Están basados en la representación unidimensional de la molécula (o representación que consiste en una lista de fragmentos estructurales de la molécula), aunque no requieren del conocimiento completo de la estructura molecular, por ejemplo, los descriptores de búsqueda y análisis subestructural, como los descriptores de conteo de fragmentos [29].
- Descriptores 2D: Son índices basados en la representación bidimensional o topológica de la molécula, o decir, que consideran la conectividad de los átomos(vértices) en la molécula (pseudografo) en términos de la presencia y naturaleza de los enlaces químicos(aristas). Esta descripción topológica de la molécula contiene información de la conectividad entre los átomos (o enlaces) en la molécula y codifica la talla, forma, ramificación, heteroátomos y la presencia de enlaces múltiples. La información importante de la molécula contenida en los DMs puede usarse en la descripción de propiedades fisicoquímicas y biológicas por ejemplo los Perfiles Moleculares e Índices de información Topológica, que son altamente predictivos para las propiedades de transporte pasivo como la permeabilidad, ya que capturan el tamaño y distribución de carga [10]). En palabras más cortas, codifican la conectividad y la forma de la molécula basándose en la teoría de grafos, sin requerir coordenadas espaciales.
- Descriptores 3D: Son índices basados no solo en la naturaleza y conectividad, si no también en la configuración espacial de la molécula.
- Huellas moleculares (*Fingerprints*): Son vectores binarios (bits 0 y 1) que indican la presencia o ausencia de subestructuras específicas. Son particularmente útiles para los algoritmos de clasificación y cálculo de similaridad, aunque su interpretabilidad directa puede ser limitada.

Dada la naturaleza del transporte pasivo en PAMPA, se espera que los descriptores relacionados con la lipofilicidad (logP, logD) y el área superficial polar (TPSA) tengan un peso preponderante en los modelos predictivos [7].

2.7.3 Curación y estandarización de datos (*Data Curation*)

En la era del *Big Data*, la calidad de los modelos predictivos depende estricta y proporcionalmente de los datos de entrenamiento (Principio “*Garbage in, Garbage out*”). La curación de datos es un paso crítico en la ingeniería de características que suele ser subestimada.

Un flujo de trabajo riguroso de curación para modelos QSAR de permeabilidad debe incluir [3]:

1. Limpieza estructural: Eliminación de contraiones, sales y moléculas de solvente para conservar únicamente el fragmento orgánico principal bioactivo
2. Normalización: Estandarización de grupos funcionales (e.g., representar grupos nitros siempre de la misma manera) y manejo de tautómeros para asegurar consistencia.
3. Manejo de duplicados: Identificación de compuestos repetidos en la base de datos. En caso de discrepancias en los valores experimentales de permeabilidad para la misma estructura, se deben aplicar criterios estadísticos (como promediar o descartar si la desviación estándar supera un umbral experimental aceptable, típicamente 0.2-0.3 unidades logarítmicas).
4. Filtrado de calidad: Descarte de datos con etiquetas inciertas o condiciones experimentales no estándar, asegurando que el modelo aprenda de datos biológicamente significantes.

2.7.4 *Machine Learning* aplicado a los modelos QSAR.

La evolución computacional ha permitido la transición de modelos QSAR lineales clásicos hacia algoritmos de aprendizaje automático (*Machine Learning*) capaces de capturar relaciones no lineales complejas entre la estructura química y la permeabilidad. La selección del algoritmo adecuado es una decisión crítica que debe balancear la capacidad predictiva con la interpretabilidad del modelo. Actualmente coexisten algoritmos clásicos de clasificación y regresión junto a técnicas avanzadas de aprendizaje en conjunto (*Ensemble Learning*) y aprendizaje profundo (*Deep Learning*). A continuación, se describen los fundamentos teóricos de los modelos evaluados en esta investigación.

2.7.4.1 Regresión logística

La regresión logística es una herramienta que permite modelar la relación entre una variable categórica binaria y un conjunto de variables explicativas continuas y/o categóricas. De la manera:

$$Y = \begin{cases} 1 & \text{si ocurre el evento(permeable)} \\ 0 & \text{no ocurre el evento(no permeable)} \end{cases}$$

La variable aleatoria $Y \sim \text{Bernoulli}(p)$ por lo que $\mathbb{E}(Y|X) = p$ donde $p \in [0, 1]$, entonces la función logística para el caso que se tengan k variables independientes queda definida de la siguiente forma:

$$\text{logit}(p) = \ln\left(\frac{\mathbb{P}(Y = 1|X)}{1 - \mathbb{P}(Y = 1|X)}\right) = \ln\left(\frac{p}{1 - p}\right) = \beta_0 + \beta_{1x_1} + \dots + \beta_{kx_k}$$

Donde se obtiene:

$$\pi(x) = \mathbb{P}(Y = 1|X) = \frac{e^{x^t\beta}}{1 + e^{x^t\beta}} = \frac{1}{1 + e^{-x^t\beta}}$$

La cual es la probabilidad que ocurra el evento de interés.

2.7.4.2 Árbol de decisión

Esta técnica predictiva de clasificación consiste en una división jerárquica y secuencial del problema en el que cada una de estas divisiones o nodos describen las decisiones posibles y, por ende, los resultados de las distintas combinaciones de eventos. A cada uno de los eventos se le asignan probabilidades y a cada una de las ramas se le determina un resultado. La mayoría de los algoritmos utilizados para construir un árbol son variaciones de uno llamado “*Greedy algorithm*”, el cual va desde la raíz hacia abajo (Top-Down) buscando de manera recursiva los atributos que generan el mejor árbol hasta encontrar el óptimo global con una estructura de árbol lo más simplificada posible [30].

Una de las ventajas de este algoritmo es su capacidad de procesar un gran volumen de información de manera eficiente y que pueden manejar de manera óptima el error en los valores o en la clasificación de estos que pudiese existir en la base de datos de entrenamiento

2.7.4.3 Random Forest

Es un método de aprendizaje supervisado de ensamblaje (ensemble learning), el cual funciona como un conjunto de múltiples Árboles de decisión (no correlacionados entre sí) que operan como un todo [31]. La ventaja de este algoritmo es que introduce una aleatoriedad extra. Al dividir un nodo, el algoritmo no busca el mejor descriptor de todos los posibles, busca el mejor descriptor dentro de un subconjunto aleatorio de descriptores. Esto obliga a los árboles ser distintos entre sí, permitiendo capturar distintos aspectos de la estructura química.

Si tienes un solo árbol, este tiene alta varianza debido a que se ajusta demasiado a los datos de entrenamiento. Al promediar muchos árboles en algunos ordenes de magnitud, reduces la varianza sin aumentar el sesgo, basándose en la “Ley de los grandes números”

En el contexto del modelado QSAR, es conveniente utilizar este algoritmo por estas razones:

Manejo de la alta dimensionalidad: En estos modelos se suele tener cientos de descriptores moleculares y fingerprints, por lo que según el contexto no es necesario realizar una selección de variables tan estricta como en una Regresión Lineal.

No requiere escalado: No se requiere normalizar estrictamente los datos a pesar de ser una buena práctica.

No-linealidad: La relación entre estructura y permeabilidad no es lineal, por lo que este algoritmo modela las fronteras de decisión complejas mediante la combinación de reglas simples.



Capítulo 3: Materiales y métodos

El flujo de trabajo computacional se diseñó siguiendo una estrategia de modelado híbrida que integra herramientas de curación molecular, selección de atributos basada en consenso y algoritmos de machine learning. El proceso se dividió en cuatro etapas secuenciales: (i) Recopilación y preprocesamiento de datos, (ii) Cálculo y reducción de descriptores moleculares, (iii) Selección de atributos y (iv) Construcción y validación del modelo predictivo.

3.1 Conjunto de datos (*Dataset*)

La base de datos (BD) experimental utilizada en este estudio se obtuvo del trabajo recientemente publicado por [32]. Esta BD, la cual incluye la mayor cantidad de valores de permeabilidad PAMPA para un total de 5447 compuestos farmacéuticos y candidatos a fármacos.

La variable dependiente (Actividad) se definió como una variable binaria (Permeable/ No permeable) basada en el umbral de permeabilidad efectiva (LogP_{eff}) establecido en la literatura de referencia ($10 \times 10^{-6} \text{ cm/s}$). Siguiendo el protocolo de partición de datos definido por los autores originales para garantizar la comparabilidad, el conjunto de datos se dividió estratificadamente en dos conjuntos independientes:

- Conjunto de entrenamiento (*Training set*): 4357 compuestos correspondientes al 80% del total, utilizado para el aprendizaje del modelo.
- Conjunto de prueba (*Test set*): 1090 compuestos correspondientes al 20% restante, utilizado para la evaluación interna.

Adicionalmente los autores emplearon un conjunto de validación externa (*External set*) compuestos por 486 compuestos. Los cuales fueron utilizados para evaluar la capacidad de generalización del modelo final ante estructuras químicas no vistas. Cabe destacar que estos compuestos no están incluidos en los dos conjuntos anteriores.

3.2 Curación y cálculo de descriptores

Empleando el paquete RDKit de Python se realizó la curación de la base de datos. Para esto se aplicó el módulo de “*Molecular Reduction*” para la estandarización estructural, realizando las siguientes tareas de limpieza:

1. Desconexión de sales y eliminación de contraiones inorgánicos.
2. Neutralización de cargas formales.

3. Eliminación de duplicados y fragmentos menores, conservando únicamente el componente orgánico principal.

La BD, ya curada, se empleó para el cálculo de los DMs utilizando el software AlvaDesc (v.2.0.10). Como se trabajó a partir de los SMILES solo se calcularon descriptores moleculares 0D-2D, así como huellas moleculares (*fingerprints*) tipo MACCS Y ECFP, generando una matriz inicial de alta dimensionalidad que captura información topológica, fisicoquímica y estructural de los compuestos. Todos los DMs calculados contienen información química de la serie de moléculas analizadas, sin embargo, no todos son significativos para discriminar que compuestos presentan permeabilidad y cuáles no. Por lo tanto, se realizó una reducción de descriptores en el propio software de cálculo eliminándose los DMs con valores: constantes, cercanos a constantes o que presentaban una correlación superior al 85%. Aun así, el número de DMs restantes fue de 783 y generar un modelo QSAR con todos ellos sería contraproducente por la complejidad que esto implica.

3.3 Análisis exploratorio de datos (EDA) y preselección

Antes de proceder con el modelado predictivo, se realizó un análisis exhaustivo en Python para comprender la estructura del espacio químico y la calidad de los datos implementando las siguientes etapas:

3.3.1 Evaluación de integridad y distribución.

Se verificó la ausencia de valores perdidos (*missing values*) o infinitos generados durante el cálculo de descriptores. Se analizó la distribución de la variable dependiente, confirmando un balance significativo en el *External set* (predominante hacia la clase permeable), lo que fundamentó la decisión posterior de aplicar técnicas de submuestreo (*undersampling*) y ponderación de clases en la etapa de validación.

3.3.2 Análisis de colinealidad.

Dada la alta dimensionalidad generada por AlvaDesc, se computó una matriz de correlación de Pearson para identificar pares de descriptores altamente redundantes. La presencia de multicolinealidad entre descriptores topológicos y constitucionales confirmó la necesidad de una estrategia agresiva de reducción de dimensionalidad para evitar el sobreajuste (*overfitting*) y reducir el costo computacional.

3.3.3 Preselección mediante eliminación recursiva (RFE)

Para optimizar el flujo de trabajo hacia la plataforma WEKA, se aplicó una técnica de RFE (por sus siglas en inglés, *Recursive Feature Elimination*) utilizando un estimador RF preliminar. Este proceso permitió reducir el espacio de características aproximadamente en un 90%, extrayendo un subconjunto refinado de las 50 variables más relevantes (basadas en la importancia de Gini).

Este conjunto, libre de ruido, compacto, excesivo pero rico en información predictiva, fue el insumo de entrada (*input*) para la selección por consenso descrita en la siguiente sección.

3.3.4 Selección de atributos (*Feature selection*)

Para reducir la dimensionalidad y eliminar variables irrelevantes o redundantes, se implementó una estrategia de selección por consenso utilizando el software WEKA, optimizado en Python.

Se aplicó un enfoque tipo *Wrapper*, evaluando cinco algoritmos evaluadores de atributos (*Genetic Search*, *Rank Search*, *Best first*, *Linear*, *ForwardSelection* y *Subset Size Forward Selection*). La selección final de descriptores se realizó mediante un sistema de votación mayoritaria: únicamente aquellos descriptores que fueron seleccionados por la mayoría de los evaluadores fueron conservados para la etapa de modelado. Esto permitió identificar un subconjunto robusto de variables predictivas independientes del algoritmo de clasificación subyacente.

3.4 Desarrollo del modelo predictivo

El modelado se llevó a cabo en lenguaje Python (v.3.9) utilizando la biblioteca *Scikit-Learn*. Se seleccionó el algoritmo *Random Forest Classifier* debido a su capacidad para manejar relaciones no lineales y su robustez ante el *overfitting*.

3.4.1 Configuración y optimización

Los hiperparámetros del modelo (número de estimadores *n_estimators*, profundidad máxima *max_depth*, criterio de división) se optimizaron mediante una búsqueda exhaustiva en rejilla (*GridSearchCV*) con validación cruzada de 5 pliegues (*k*=5) sobre el conjunto de entrenamiento.

3.4.2 Manejo del desbalance de clases

Dado que el conjunto de datos externo presentaba un balance significativo hacia la clase permeable, se implementó una estrategia dual para evitar sesgos en la predicción:

1. *Undersampling*: Se aplicó una técnica de reducción aleatoria de la clase mayoritaria en el set de validación para equilibrar la distribución de clases durante la evaluación.
2. *Ponderación de clases (Class weighting)*: En el algoritmo *Random forest*, se asignó el parámetro *class_weight='balanced'*, otorgando un peso mayor a la clase minoritaria (no permeable) durante el entrenamiento para penalizar fuertemente los errores de clasificación en esta categoría.

3.5 Métricas de clasificación

3.5.1 Matriz de confusión

Para estudiar las diferentes métricas de clasificación es necesario definir la matriz de confusión, que es una forma tabular de resumir la información sobre los éxitos y fracasos en la predicción

de los modelos. Cabe mencionar, que categoriza las predicciones de acuerdo con su coincidencia con el valor real de la categoría (Visa et al 2011). En este caso, al analizar un problema de clasificación binaria, donde los valores tomados por la variable objetivo son Act1 y Act-1 (1 y 0), donde se hace referencia a si es permeable o no permeable respectivamente. De forma ilustrativa se tiene la siguiente matriz (ver Figura 5):

PREDICCIÓN: Positiva	VP (Verdaderos Positivos)	FP (Falsos Positivos)
PREDICCIÓN: Negativa	FN (Falsos Negativos)	VN (Verdaderos Negativos)
	REALIDAD: Positiva	REALIDAD: Negativa

Figura 5. Representación gráfica de una matriz de confusión

A partir de la construcción de esta matriz, posteriormente se entenderá de mejor manera cada una de las medidas de rendimiento utilizadas en los distintos modelos implementados.

Exactitud

La exactitud o Accuracy se define como el cómo el cociente entre el número de casos clasificados correctamente entre el total de casos. Representa el porcentaje de aciertos del modelo. Mide la frecuencia con la que el clasificador realiza la predicción correcta

$$\begin{aligned} \text{Accuracy} &= (\text{clasificaciones correctas})/(\text{clasificaciones totales}) \\ &= (TP + TN)/(TP + TN + FP + FN) \end{aligned}$$

Corresponda a la métrica más sencilla y la más utilizada, no obstante, resulta algo inexacta debido a que no tiene en cuenta la distribución del error entre las clases.

Para evaluar el desempeño de modelos de clasificación en bioinformática, no basta con la exactitud, es necesario analizar métricas que consideren el balance entre clases como el coeficiente de correlación de Matthews (MCC) y el área bajo la curva ROC (AUC)[33].

Precision

Esta nos indica que proporción de eventos clasificamos como positivos realmente son positivos. Se define matemáticamente como:

$$\text{Precision: } (\text{positivos clasificados correctamente}) / (\text{todo lo clasificado como positivo}) = TP / (TP + FP)$$

Sensibilidad o Recall

Nos indica que proporción de eventos positivos que fueron clasificados correctamente. Es una proporción de verdaderos positivos a todos los positivos. Responde a la pregunta ¿Qué proporción de positivos reales se identificó correctamente?

$$\text{Recall} = (\text{positivos calsificados correctamente}) / (\text{todos los positivos}) \\ = TP / (TP + FN)$$

Especificidad

Es la capacidad de una prueba de detectar correctamente los verdaderos negativos y suele estar inversamente relacionada con la sensibilidad.

$$\text{Specificity} = TN / (TN + FP)$$

Curva ROC (Receiver operating characteristic curve)

Método estadístico para determinar la exactitud diagnostica de un determinado test que utiliza escalas continuas siendo utilizadas con tres propósitos específicos: determinar el punto de corte en el que se alcanza la especificidad y la sensibilidad más alta, evaluar la capacidad discriminativa del modelo, es decir, su capacidad de diferenciar positivos vs negativos y comparar la capacidad discriminativa de dos o más modelos que expresan sus resultados como escalas continuas (Patit et al 2013)

F1-Score

Existe un ponderado entre Precision y Recall, representa la media armónica entre ambos fenómenos. Se prefiere el F1 dado que penaliza de mayor manera los valores bajos, alcanza un máximo de 1 cuando Precision y Recall son 1, y 0 cuando ambas son 0, aun cuando una de las medidas sea 1. Se utiliza dado que pondera de mayor manera a los valores bajos. Esto genera que F1 sea alto solo cuando ambos lo sean. Matemáticamente se expresa como:

$$F1 = (2 \times \text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$



Capítulo 4: Resultados y discusiones

4.1 Visualización del Dataset.

Con el fin de reducir el ruido y hacer los modelos más eficientes y lógicos se aplicó un EDA.

En el siguiente gráfico (ver Figura 6) se visualiza el balance en el set de entrenamiento, el cual está balanceado hacia los que son permeables, ya que la barra “Act1” es más alta que la de “Act-1”, esto indica un Dataset desbalanceado hacia los positivos, por lo que usar solo la exactitud para evaluar el modelo es ineficiente y se necesita mirar otras métricas como el F1-score el cual es sensible al desbalance.




Figura 6. Distribución de clases en el conjunto de entrenamiento.

4.2 Análisis de relevancia de atributos.

Con el fin de reducir la dimensionalidad se sometió el conjunto de 783 DMs a un análisis de varianza (ver Figura 7). El objetivo de este filtro fue identificar y eliminar aquellas variables que presentaban pequeña varianza en sus valores ($\text{var} < 0.05$), dado que estos descriptores no aportan buena capacidad discriminante al modelo.




Figura 7. Análisis de relevancia de los descriptores.

Tras este procedimiento, se eliminaron cinco variables, resultando en un conjunto de 778 descriptores operativos. Esta reducción marginal (menos del 1%) indica que la gran mayoría de las propiedades calculadas presentan variabilidad dentro del espacio químico estudiado, lo cual confirma la riqueza informativa del Dataset inicial, pero a la vez, subraya la necesidad de aplicar métodos de selección más estrictos en etapas posteriores para manejar la alta dimensionalidad.

4.3 Análisis de Mann-Whitney

Se calculo el *p-value* para las 778 variables restantes. Los descriptores estadísticamente significantes con un *p-value* < 0.05




Figura 8. Descriptores significativos dentro de los valores *p-value* esperados.

Se evaluó la relevancia estadística de los descriptores restantes mediante la prueba no paramétrica U de Mann-Whitney (ver Figura 8) ($\alpha=0.05$), comparando las poblaciones de compuestos activos e inactivos. Los resultados indican que 126 variables no presentaban diferencias significativas entre las clases, por lo que fueron descartadas, de este modo, se conservaron 652 descriptores con capacidad discriminante.

4.4 Análisis de correlación de Spearman

Para evitar la multicolinealidad y reducir la redundancia intrínseca del conjunto de datos se estableció un umbral de corte estricto de $|r| > 0.9$. Cuando dos variables superan este coeficiente, se consideran portadoras de información redundante, procediendo a eliminar aquella con menor correlación individual respecto a la variable objetivo (Actividad). Se eliminaron 122 variables con alta correlación, por lo que quedaron 530 descriptores independientes. En la Figura 9 se pueden ver ejemplos de la muestra de los cuales se descartarán por estar de color rojo intenso.




Figura 9. Análisis de correlación de Spearman (Top 20). Se descartan el par de variables que superan el umbral establecido.




Figura 10. Top 30 variables importantes según importancia de Gini.

4.3 Recursive Feature Elimination (RFE)

Cuando se crea el modelo completo, se calcula una medida de importancia variable que clasifica los predictores del más al menos importante. En cada etapa de la búsqueda, los predictores menos importantes se eliminan iterativamente antes de reconstruir el modelo.

Las características se clasifican utilizando un modelo de aprendizaje automático proporcionado (por ejemplo, algunos algoritmos de tipo árbol ofrecen puntajes de importancia) o utilizando un método estadístico.

Los cálculos de importancia pueden basarse en modelos (por ejemplo, el criterio de importancia del *Random Forest*) o utilizar un enfoque más general que sea independiente del tipo de modelo. Se aplicó el RFE sobre el conjunto de descriptores restantes, se evaluó la interacción conjunta de los datos y su contribución real al rendimiento predictivo. De este proceso se extrajo un conjunto final de las 50 variables más relevantes. Esta reducción del ~90% respecto al set previo tuvo como objetivo generar un conjunto de datos compacto y de alta calidad para ser utilizado en WEKA para optimizar el costo computacional sin sacrificar poder predictivo. En la Figura 10 se pueden observar por orden de importancia los 30 mejores descriptores encontrados.

4.5 Selección de Características

Tras el análisis exploratorio y la curación de datos inicial, se procedió a la reducción de la dimensionalidad. Si bien se pueden construir modelos de tipo árbol como Parasar et al [32] . Con ese número de DMs totales, buscamos que tengan sentido fisicoquímico. Se implementó una estrategia de selección por consenso. Este enfoque permite identificar las características fisicoquímicas y estructurales más robustas, mitigando el sesgo inherente al utilizar un único algoritmo de selección.

4.5.1 Metodología de selección automatizada en WEKA

Para garantizar la exhaustividad del proceso, se desarrolló un script de automatización en Python (`weka_cmd1.py`) que interactúa con la plataforma de minería de datos WEKA. Esto permitió la ejecución paralela de 10 estrategias de selección de atributos distintas, combinando métodos de tipo *Filter* (basados en propiedades estadísticas de los datos) y *Wrapper* (que evalúan subconjuntos de variables utilizando un algoritmo de aprendizaje predictivo).

4.5.2 Análisis de Consenso

Para mitigar la colinealidad y reducir el riesgo de sobreajuste, se aplicó una estrategia de selección de características por consenso en dos etapas.

1. Etapa de votación: Se estableció un umbral de corte inicial del 40% (4 votos), identificando un conjunto primario de descriptores candidatos.
2. Etapa de Parsimonia: Se evaluó el impacto de los descriptores con 40% de votos en el desempeño del modelo. Se observó que la inclusión de ciertas variables disminuía los parámetros estadísticos de calidad. En consecuencia, se seleccionaron únicamente 11 descriptores finales que maximizaban la capacidad predictiva sin comprometer la estabilidad del modelo.

En la tabla 1 se muestran los 11 descriptores seleccionados, junto a su definición y familia química, junto a su interpretación mecanística.

4.6 Validación del modelo

Para evaluar la capacidad predictiva del Random Forest, se analizaron las métricas de desempeño en el set de entrenamiento, en el set interno y un externo, además se añadió una validación cruzada. La tabla 2 resume los resultados obtenidos tras el proceso de optimización de parámetros.

Tabla 1. Descriptores moleculares empleados en el modelo *Random Forest*.

Descriptor	Familia/tipo	Definición	Interpretación mecanística
LOGPcons (70%)	Fisicoquímico	<i>Consensus</i> LogP. Logaritmo del coeficiente de reparto octanol-agua	Lipofilicidad. Es el parámetro termodinámico más crítico en la permeabilidad pasiva. Determina la afinidad del fármaco por la fase lipídica de la membrana
MACCSFP125 (60%)	Fingerprints	MACCS <i>key</i> 125. Bit binario que indica la presencia de anillos aromáticos con heteroátomos.	Reconocimiento estructural. Captura características 2D (farmacóforos) que pueden favorecer interacciones dentro de la bicapa lipídica (ej. π - <i>stacking</i>)
Psi_e_A (60%)	Electro topológico	<i>Intrinsic state pseudoconnectivity index</i> . Índice de pseudoconectividad ponderado con la electronegatividad de Sanderson	Distribución electrónica. Modela la accesibilidad de los electrones de valencia en la topología molecular, influyendo en interacciones electroestáticas con las cabezas polares de los fosfolípidos.
PCR (60%)	Topológico	<i>Ratio of multiple paths counts to path counts</i> . Relación entre conteos de caminos múltiples y simples	Complejidad y forma. Un valor alto indica una estructura altamente ramificada o con múltiples ciclos, lo cual puede generar un impedimento estérico, dificultando la difusión en la membrana.
Mp (50%)	Propiedad atómica	<i>Mean atomic polarizability</i> . Polarizabilidad atómica media (respecto al átomo de Carbono)	Polarizabilidad. Representa la capacidad de la nube electrónica para deformarse, facilitando las interacciones dipolo inducido (fuerzas de dispersión de London) con las cadenas hidrocarbonadas de los lípidos.
P_VSA_ppp_D (50%)	Superficie	<i>P_VSA-like on potential pharmacophore points (Donor)</i> . Suma de superficies de Van der Waals asociadas a donadores de H ⁺	Desolvatación. Los grupos donadores de enlaces de H (ej. -OH, -NH) aumentan la afinidad por el agua. Un alto valor suele penalizar la permeabilidad debido al costo energético antes de entrar a la membrana
SpMin1_Bh(p) (50%)	Matriz de Burden	<i>Smallest eigenvalue n.1 of Burden matrix. (weighted by polarizability)</i> . Auto valor menor de la matriz ponderado por polarizabilidad	Topología de zonas blandas. Descriptor matemático complejo que mapea la distribución topológica de las regiones polarizables de la molécula, refinando la predicción de interacciones no covalentes
SM12_AEA (ri) (40%)	Momento espectral	Spectral moment of order 12(Augmented edge adjacency mat.) ponderado por la integral de resonancia	Conjugación y aromaticidad. Al ponderarse por la integral de resonancia, detecta sistemas conjugados extensos. La deslocalización electrónica afecta tanto la geometría planta como la estabilidad lipofílica
SHED_AL (40%)	Entropía	<i>Shannon entropy descriptor (Acceptor-Lipophilic)</i> . Entropía de Shannon aplicada a la distribución de aceptores de H ⁺ y zonas lipofílicas	Anfipaticidad. Mide la diversidad espacial y el equilibrio entre zonas polares (aceptores) y apolares. Una distribución equilibrada suele favorecer el paso a través de interfaces heterogéneas.
MATS5m (40%)	Autocorrelación 2D	<i>Morgan autocorrelation of lag 5</i> . Autocorrelación especial de la masa atómica en una distancia topológica de 5 enlaces.	Distribución de masa. Describe patrones de tamaño y forma a larga distancia dentro de la molécula, diferenciando isómeros estructurales con distinta distribución espacial
P_VSA_s_3(40%)	Estado intrínseco	<i>P_VSA-like on intrinsic state</i> (bin 3). Suma de superficial VSA de átomos que caen en el intervalo 3 del estado electro topológico intrínseco.	Reactividad local específica. Agrupa átomos con un estado electrónico específico (potencialmente oxígenos de éter o carbonilos) que modulan la interacción acuosa/lipídico sin ser fuertemente polares.

Bondad de ajuste y robustez

El modelo mostro una notable capacidad de aprendizaje durante la fase de entrenamiento alcanzando un área bajo la curva ROC(AUC) de 0.94 y una exactitud del 0.863% junto con un F1-Score de 0.869 (ver Figura 11).

Tabla 2. Parámetros estadísticos alcanzados por el modelo.

Dataset	Exactitud	Sensibilidad	Especificidad	AUC	MCC	F1-Score
Entrenamiento	0.863	0.851	0.876	0.94	0.725	0.869
Validación cruzada (k=5)	0.718	0.731	0.705	0.80	0.437	0.722
Validación Interna	0.750	0.758	0.740	0.831	0.497	0.764
Validación Externa	0.891	0.939	0.395	0.686	0.331	0.940

Al someter el modelo al conjunto de Test Interno (compuestos no vistos durante el ajuste de parámetros). se observó una capacidad de generalización adecuada. El F1-Score se mantuvo en 0.764. un valor que supera los umbrales estándar de aceptación en modelado QSAR para propiedades ADME complejas. A diferencia de métricas globales como la exactitud. que pueden verse sesgadas por el desbalance de clases. el F1-Score confirma que el modelo retiene su afinidad para recuperar compuestos permeables incluso en nuevos datos. manteniendo un equilibrio coherente entre Sensibilidad (0.758) y Especificidad (0.74)




Figura 11. Curvas ROC para el conjunto de entrenamiento y el conjunto de validación interna.

4.6.1 Validación Cruzada

Para evaluar la capacidad de generalización del modelo y evitar el sobreajuste, se realizó una validación cruzada utilizando el conjunto de datos balanceados. Se compararon esquemas de 5 y 10 particiones ($k=5$ y $k=10$) para determinar la estabilidad de las métricas predictivas. La tabla 3 muestra el desempeño promedio obtenido en las iteraciones de validación.

Se selecciono el esquema de cinco particiones ($k=5$) como el más adecuado. A pesar de que el promedio del área bajo la curva (ROC AUC) es similar en ambos casos (0.8), los cinco pliegues demostraron una mayor estabilidad, evidenciada por una menor desviación estándar en la especificidad (± 0.07 frente a ± 0.11 en $k=10$).

Un valor de AUC de 0.8 indica que el modelo tiene una probabilidad del 80% de clasificar correctamente un compuesto permeable frente a uno no permeable al azar, lo que se considera un rendimiento predictivo óptimo para herramientas de cribado virtual en etapas tempranas.

Además, el equilibrio entre sensibilidad (0.731) y especificidad (0.705) sugiere que el modelo no está sesgado hacia ninguna de las clases mayoritarias.

Tabla 3. Resultados de la validación cruzada para el modelo de clasificación.

Métrica	K-Fold = 5 (Promedio $\pm$ DE)	K-Fold = 10 (Promedio $\pm$ DE)
ROC AUC	0.800 $\pm$ 0.04	0.802 $\pm$ 0.06
Sensibilidad	0.731 $\pm$ 0.02	0.730 $\pm$ 0.02
Especificidad	0.705 $\pm$ 0.07	0.710 $\pm$ 0.11

(DE: Desviación Estándar. El modelo utilizado fue Random Forest.)

4.6.2 Validación externa

La prueba de “fuego” del modelo se realizó frente a un conjunto de validación externa independiente. Los resultados revelan un comportamiento altamente favorable para aplicaciones futuras para un cribado virtual (*Virtual Screening*). Destaca por, sobre todo, un F1-Score de 0.94 en la validación externa, impulsado por una Sensibilidad del 93.9% y un Accuracy del 0.89, lo que implica que el modelo es capaz de identificar la inmensa mayoría de los fármacos permeables presentes en la muestra. El alto valor de F1 indica que, para el propósito del *Drug Discovery*, el modelo es sumamente eficaz, priorizando no perder ningún candidato potencialmente valioso (baja tasa de falsos negativos). En un flujo de trabajo de descubrimiento temprano, este perfil de desempeño es preferible, ya que actúa como un filtro de seguridad que maximiza la recuperación de activos, delegando la confirmación de los negativos a etapas experimentales posteriores. Sin embargo, la Especificidad descendió a 0.395 en el conjunto externo. Este fenómeno puede atribuirse a dos factores:

1. Desbalance de clases en la validación externa: Si el conjunto externo tiene una baja proporción de compuestos no permeables, un pequeño número de falsos positivos penaliza drásticamente la especificidad matemática.

2. Sesgo hacia la seguridad (High recall): El modelo tiende a clasificar la incertidumbre como “Permeable”. En un contexto de cribado virtual, este comportamiento es ventajoso (“*Conservative Filter*”), ya que minimiza el riesgo de descartar falsos negativos, a costa de admitir algunos falsos positivos que serán depurados en ensayos posteriores.

En conclusión, el modelo es propuesto como una herramienta eficaz de enriquecimiento de librerías, capaz de recuperar el 94% de los candidatos permeables potenciales. No obstante, es importante reconocer que la especificidad en el conjunto de validación externa desciende a 0.395, lo que indica que una fracción significativa de compuestos no permeables es clasificada erróneamente como permeable. Este comportamiento sugiere que el modelo tiende a predecir la mayoría de nuevas moléculas como permeables, lo cual, si bien resulta ventajoso como filtro conservador en cribado temprano, debe considerarse al interpretar predicciones individuales. La incorporación de conjuntos de validación externa con mayor proporción de compuestos no permeables permitiría en el futuro fortalecer la especificidad del modelo.

Para confirmar la utilidad práctica del modelo frente a nuevas entidades químicas, se evaluó su desempeño utilizando un conjunto de prueba (External set) compuesto por 486 moléculas que no formaron parte del entrenamiento.

La Figura 12 presenta la matriz de confusión obtenida, detallando la correspondencia entre las clases reales y predichas.

		Validación Externa (External Set)	
Dato Experimental Real	Activo	416 (TP) Verdadero Positivo	27 (FN) Falso Negativo
	Inactivo	26 (FP) Falso Positivo	17 (TN) Verdadero Negativo
		Activo	Inactivo
		Predicción del Modelo	

Figura 12. Matriz de confusión para el conjunto de validación externa.

El análisis sugiere que el modelo posee una exactitud del 89.1%, clasificando correctamente 433 de las 486 moléculas evaluadas.

4.7 Comparación con modelos QSAR reportados en la literatura.

Con el fin de evaluar el desempeño de los modelos desarrollados en este estudio, se realizó una comparación con modelos QSAR previamente reportados en la literatura desarrollados para la predicción de la permeabilidad intestinal pasiva medida mediante el ensayo PAMPA. La Tabla 4 muestra el resumen de los principales trabajos publicados en los últimos años, comparando con relación al tamaño del conjunto de datos, a la presencia de validación externa independiente y a métricas de desempeño ampliamente aceptadas como: AUC, exactitud balanceada (*balanced accuracy* BACC), sensibilidad, especificidad y coeficiente Kappa.

Los valores de los estadísticos reportados en la Tabla 4 se corresponden con los del test interno (excepto para el modelo que no presenta serie de test) esto se debe a que los trabajos anteriores reportaron estos valores y para poder comparar nuestro modelo con los anteriores reportamos los valores estadísticos para la misma serie.

Como puede verse en la tabla los modelos desarrollados con el mayor número de compuestos Siramshetty *et al.*, (más de 16 mil compuestos) [34] también son los que presentan mayores valores de exactitud/sensibilidad/especificidad (0.82/0.78/0.86-0.84). Sin embargo, la base de datos empleada por esos investigadores no está disponible haciendo imposible replicar el estudio y contrastar los resultados por ellos publicados. Esta dificultad la comparte los modelos desarrollados por Jordan Williams *et al.*, (6500 compuestos) [35] los cuales presentaron valores de exactitud (0.77) similares a los de nuestro modelo (0.75) con valores de sensibilidad de 0.69 los cuales son inferiores al alcanzado por nuestro modelo que fue de 0.75. Si bien los valores de AUC, BACC, sensibilidad y especificidad del modelo reportado en este trabajo son ligeramente inferiores. Vale destacar que algunos de estos enfoques están desarrollados empleando redes neuronales profundas o grafos convolucionales (GCNN, GAT), mientras nuestro modelo prioriza la interpretabilidad, lo cual constituye una ventaja clave para su aplicación en diseño racional de fármacos.

Entre los modelos desarrollados con bases de datos disponibles el de Kato *et al.* [36] emplea menor número de compuestos y los valores de los principales estadísticos son inferiores a los mostrados por nuestro modelo basado en *Random forest*. Un aspecto relevante del presente estudio es el equilibrio observado entre sensibilidad y especificidad. Mientras que los modelos desarrollados por Kato *et al.*, [32] maximizan la especificidad (0.87-0.92) a expensas de una sensibilidad reducida (0.45-0.53), el modelo desarrollado en nuestro trabajo muestra una sensibilidad elevada en la validación externa, lo que resulta especialmente adecuado para aplicaciones de cribado virtual temprano, donde minimizar falsos negativos es prioritario. Este comportamiento conservador permite identificar la mayoría de los compuestos potencialmente permeables, delegando la depuración de falsos positivos a etapas experimentales posteriores.

Al comparar nuestro modelo con el trabajo de Parasar *et al.* [32], que utiliza el mismo conjunto de datos PAMPA y la misma validación externa independiente de 486 compuestos, los modelos de estos investigadores alcanzan valores de AUC (0.87) y BACC (0.78) ligeramente superiores a los de nuestro modelo, mientras su sensibilidad se encuentra en el orden de 0.66 siendo este valor bastante menor al que alcanza nuestro modelo (0.75). También debe tenerse en cuenta que sus modelos fueron desarrollados con un número de más de 50 descriptores mientras nuestro modelo fue desarrollado con solamente 11 descriptores. Como dijimos antes nuestro modelo

además de ser más transparente muestra una sensibilidad elevada lo cual como dijimos anteriormente es muy deseado en etapas tempranas del proceso de desarrollo de medicamentos.

Tabla 4. Tabla comparativa modelos QSAR reportados en la literatura.

Trabajos	Tamaño de la base de datos	Validado con serie externa (No de compuestos)	Modelo obtenido	AUC	BACC	Sensibilidad	Especificidad	Kappa
Siramsshetty et al., 2021 [34]	16624	Si (2664)	RF	0.9	0.82	0.78	0.86	0.64
			GCNN	0.9	0.82	0.78	0.84	0.65
Jordan Williams et al., 2022 [35]	6500	Si (1046)	RF (RDKit)	0.83	0.77	0.69	0.86	0.41
			XGB (RDKit)	0.83	0.77	0.69	0.86	0.44
			DNN (RDKit)	0.8	0.72	0.63	0.83	0.32
			RF (MorganFP)	0.78	0.71	0.63	0.83	0.32
			XGB (MorganFP)	0.77	0.73	0.65	0.82	0.34
			DNN (MorganFP)	0.77	0.73	0.65	0.82	0,34
Kato et al., 2023 [36]	1958	No	GCNN	0.79	0.69	0.53	0.87	--
			RF (RDKit)	0.79	0.69	0.53	0.87	--
			XGB (RDKit)	0.78	0.69	0.53	0.87	--
			HGB (RDKit)	0.77	0.66	0.49	0.92	--
			GCNN (MorganFP)	0.77	0.66	0.49	0.92	--
			RF (MorganFP)	0.74	0.63	0.46	0.9	--
			XGB (MorganFP)	0.73	0.63	0.46	0.9	--
			HGB (MorganFP)	0.72	0.62	0.45	0.91	--
Parasar et al., 2025 [32]	5477	Si (486)	RF	0.87	0.78	0.66	0.88	0.62
			EBM	0.87	0.78	0.66	0.88	0.61
			AdaBoost	0.82	0.75	0.66	0.84	0.50
			GAT	0.83	0.71	0.67	0.8	0.47
Este trabajo	5447	Si (486)	RF	0.83	0.75	0.75	0.65	0.5

En resumen y teniendo en cuenta los elementos brindados en este epígrafe podemos decir que estos resultados posicionan al modelo propuesto en nuestro trabajo como una alternativa competitiva y metodológicamente sólida frente a enfoques previamente publicados, con la ventaja adicional de ofrecer interpretabilidad fisicoquímica y aplicabilidad directa en flujos de trabajo de cribado virtual y optimización temprana de compuestos.

4.8 Cribado de bases de datos de interés

Con el objetivo de evaluar la aplicabilidad práctica y el comportamiento prospectivo de los modelos QSAR desarrollados, en esta sección se presentan dos estrategias de cribado complementarias. En primer lugar, se realiza un cribado simulado sobre un conjunto reducido de compuestos recientemente reportados en la literatura, no incluidos en las etapas de entrenamiento ni validación, con el fin de analizar la capacidad del modelo para clasificar nuevas entidades moleculares en un escenario controlado. Posteriormente, se aplica un cribado virtual a gran escala sobre la base de datos DrugBank, orientado a explorar la utilidad del modelo como herramienta de filtrado temprano y enriquecimiento de bibliotecas químicas dentro de su dominio de aplicación. En conjunto, ambos enfoques permiten evaluar la transferencia, robustez y potencial impacto del modelo en contextos reales de descubrimiento temprano de fármacos.

4.8.1 Cribado simulado






Para evaluar la utilidad práctica de los modelos QSAR desarrollados, se realizó una predicción (cribado simulado) sobre un conjunto reducido de moléculas descritas recientemente en la literatura científica, que no formaron parte ni del conjunto de entrenamiento ni del de validación. Este análisis tiene un carácter cualitativo y exploratorio, orientado a examinar la transferibilidad del modelo a nuevos quimiotipos.

El conjunto de moléculas analizado incluyó tres derivados de 4-hidrazono-pirazolidindionas reportados por Waahed et al. [37], además de dos patrones (positivo y negativo) empleados para el ensayo PAMPA. Estos derivados fueron diseñados como ligandos multitarget (COX-2, amiloide-B, tau) para el tratamiento de la enfermedad de Alzheimer. Aunque los autores demostraron su potencial para cruzar la Barrera Hematoencefálica (BBB) mediante ensayos PAMPA-BBB, la permeabilidad intestinal (PAMPA-GIT) es un requisito previo indispensable para su administración oral eficaz. Aunque los valores experimentales disponibles corresponden a PAMPA-BBB, ambos ensayos comparten el principio fisicoquímico de difusión pasiva, por lo que este ejercicio se plantea como una evaluación de consistencia mecanística más que una comparación cuantitativa directa.

Aunque describen otros derivados para el ensayo de PAMPA, solo emplearon los tres mejores ligandos *multitarget* identificados con los números 2, 3 y 7 en el artículo. Para estos compuestos y los dos patrones se calcularon los descriptores moleculares y se evaluaron en el modelo Random Forest optimizado. En la tabla 4 se muestran: las estructuras de los compuestos, la clasificación del modelo y los valores experimentales reportados por [37] El modelo clasificó

correctamente los tres derivados y el control positivo como permeables, y al control negativo como no permeable, mostrando una concordancia cualitativa completa con los datos experimentales reportados en el artículo, teniendo en cuenta que el valor de corte empleado en el modelo fue de 10×10^{-6} nm/s. Este comportamiento es coherente con los descriptores seleccionados en el modelo, particularmente aquellos asociados a lipofilidad y polarizabilidad, reforzando la plausibilidad fisicoquímica de las predicciones.

Tabla 5. Resultados del Cribado simulado.

ID Compuesto	Estructura Química	Clasificación del Modelo	Permeabilidad ($\times 10^{-6}$ nm/s)
Compuesto 2		+	11.1 ± 0.43
Compuesto 3		+	12.1 ± 0.27
Compuesto 7		+	11.7 ± 0.51
Donepezil		+	22.4 ± 0.49
Norfloxacin		-	1.43 ± 0.08

4.8.2 Cribado Virtual

Con el objetivo de validar la utilidad del modelo como herramienta de filtrado en el descubrimiento de fármacos, se ejecutó un protocolo de cribado virtual (Virtual screening) sobre la base de datos *DrugBank*. El objetivo fue identificar estructuras químicas con alta permeabilidad pasiva que, simultáneamente, cumplan con los requisitos estructurales para ser considerados fármacos orales (“drogabilidad”).

4.8.2.1 Protocolo de filtrado en embudo (*Funneling*)

El proceso se diseñó como un flujo de trabajo secuencial de tres etapas, aplicando criterios de eliminación progresiva para maximizar la calidad de los candidatos finales:

1. Evaluación del dominio de aplicación (AD): Se calculó el valor de apalancamiento (*leverage*) para cada compuesto de la biblioteca. Se estableció un umbral de seguridad estricto de $h^* = 0.0083$. Aquellas moléculas con $h > h^*$ fueron descartadas por considerarse estructuralmente distintas al conjunto de entrenamiento, garantizando así la fiabilidad de las predicciones posteriores.
2. Predicción de Actividad: Se aplicó el modelo de clasificación a los compuestos dentro del dominio. Se seleccionaron únicamente aquellos candidatos con una probabilidad de clase (Permeable) superior al 60%.
3. Filtro de drogabilidad (Lipinski): A los candidatos restantes se les aplicó la “Regla de los 5 de Lipinski” ($MW < 500$, $\text{LogP} < 5$, Donadores H < 5 , Aceptores H < 10) para asegurar un perfil farmacocinético oral favorable.

4.8.2.2 Resultados del cribado

El modelo demostró una alta capacidad de discriminación: de la fase de predicción se obtuvieron inicialmente 868 candidatos clasificados como permeables de alta confianza. Tras aplicar el filtro de propiedades fisicoquímicas de Lipinski, se obtuvo una lista final de 784 compuestos “drogables” de alta permeabilidad predicha. Esto sugiere que el modelo no solo identifica moléculas permeables, sino que los descriptores seleccionados (como LOGPcons y PCR) correlacionan implícitamente con características de buena biodisponibilidad.

Se detectó una diversidad estructural significativa en los resultados. Identificándose 11 familias químicas (ver Figura 13; *Scaffolds*) diferentes entre los candidatos, lo que indica que el modelo no está sesgado hacia un tipo único de estructura química.

Tabla 6. Top 10 compuestos identificados en el Cribado Virtual

ID (DrugBank)	Nombre Genérico	Probabilidad (Permeabilidad)	MW (g/mol)	LogP	Uso	Estado
DB06209	[Prasugrel]	0.980	409.91	4.31	Antiplaquetario	Aprobado
DB01656	[Vatalanib]	0.978	403.21	5.03	Antineoplásico	Investigación.
DB00838	[Clopidogrel]	0.976	495.03	4.60	Antiplaquetario	Aprobado
DB02300	[Calcipotriol]	0.970	412.61	5.09	Anti psoriásico	Aprobado
DB00317	[Gefitinib]	0.970	446.91	4.28	Antineoplásico	Aprobado
DB00401	[Propanolol]	0.970	388.42	3.20	Betabloqueante	Aprobado
DB00559	[Verapamilo]	0.970	551.63	4.20	Antiarrítmico	Aprobado
DB04967	[Lucanthone]	0.970	340.49	4.48	Antiparasitario	Aprobado
DB04715	[Imidazopyridazine]	0.970	306.37	3.42	Scaffold	Experimental
DB00269	[Clorpromazina]	0.960	380.87	5.87	Antipsicótico	Aprobado




Figura 13. Ejemplos de *Scaffolds* encontrados.



Capítulo 5: Conclusiones

De acuerdo con los objetivos planteados y tras el análisis de los resultados obtenidos en el desarrollo del modelado QSAR para la predicción de la permeabilidad en PAMPA, se concluye lo siguiente:

1. Cumplimiento del objetivo general: Se logró desarrollar y validar exitosamente modelos QSAR interpretables y generalizables para la predicción de la permeabilidad pasiva. La integración de descriptores moleculares con el algoritmo Random Forest permitió obtener una herramienta con una capacidad predictiva consistente, equilibrando precisión y estabilidad. Esto valida que el uso de técnicas de Machine Learning constituye una estrategia eficaz para modelar fenómenos biológicos complejos, superando las limitaciones de los enfoques lineales tradicionales y proporcionando una alternativa confiable a la experimentación *in vitro*.
2. Conformación de una base de datos robusta: Se cumplió con el objetivo de recopilar y curar una base de datos de alta calidad. Mediante protocolos rigurosos de estandarización química y limpieza de datos, se consolidó un set de entrenamiento consistente, eliminando duplicados y corrigiendo errores estructurales. Esto asegura la fiabilidad del *endpoint* biológico (permeabilidad en PAMPA), proporcionando una base libre de ruido experimental que fue determinante en el rendimiento alcanzado.
3. Implementación de modelos de *Machine Learning*: La implementación computacional permitió construir y comparar diversos modelos de clasificación, determinando que el Random Forest es el algoritmo óptimo para este dominio. El modelo final demostró un excelente desempeño en el aprendizaje de patrones estructura-actividad, alcanzando un AUC de 0.94 en la fase de entrenamiento. Además, se logró mejorar la interpretabilidad del modelo mediante el análisis de importancia de características, identificando descriptores fisicoquímicos claves que gobiernan la permeabilidad intestinal pasiva.
4. Validación según principios OCDE: El modelo fue sometido a una validación estadística exhaustiva siguiendo los lineamientos de la OCDE, cumpliendo satisfactoriamente en todos los criterios:

- Validación interna: La validación cruzada arrojó con AUC de 0.80, demostrando robustez sin sobreajuste.
 - Validación externa: La evaluación con el set independiente de 486 compuestos (no utilizados en el entrenamiento), obteniendo métricas destacadas como (Exactitud=0.89, F1-Score=0.94, Sensibilidad= 0.94). que garantizan su generalización.
 - Dominio de aplicación: Se definió el dominio de aplicabilidad mediante el método de leverage, asegurando que las predicciones futuras se realicen dentro de un espacio químico confiable.
5. Evaluación del desempeño prospectivo: El modelo predijo correctamente la permeabilidad en las moléculas reportadas por Waheed et al.[37] , validando su capacidad prospectiva frente nuevas entidades moleculares. La aplicación del modelo sobre la BD *DrugBank* permitió filtrar e identificar eficazmente candidatos con perfiles de permeabilidad favorables. Esto confirma que el modelo desarrollado es apto para ser integrado en flujos de trabajo de descubrimiento de fármacos, permitiendo priorizar compuestos de interés comercial y terapéutico

Capítulo 6: Referencias

- [1] J. A. DiMasi, H. G. Grabowski, and R. W. Hansen, “Innovation in the pharmaceutical industry: New estimates of R&D costs,” *J. Health Econ.*, vol. 47, pp. 20–33, May 2016, doi: 10.1016/j.jhealeco.2016.01.012.
- [2] Kola Ismail and Landis John, “kola2004,” *Nature Reviews*, Aug. 2004.
- [3] A. Avdeef, “Frontmatter,” in *Absorption and Drug Development*, Wiley, 2012. doi: 10.1002/9781118286067.fmatter.
- [4] V. Siramshetty *et al.*, “Validating ADME QSAR Models Using Marketed Drugs,” *SLAS Discovery*, vol. 26, no. 10, pp. 1326–1336, Dec. 2021, doi: 10.1177/24725552211017520.
- [5] H. Le-Thi-Thu, Y. Cañizares-Carmenate, Y. Marrero-Ponce, F. Torrens, and J. A. Castillo-Garit, “Send Orders for Reprints to reprints@benthamscience.ae Letters in Drug Design Prediction of Caco-2 Cell Permeability Using Bilinear Indices and Multiple Linear Regression,” 2016.
- [6] H. Lennernäs, “Intestinal permeability and its relevance for absorption and elimination,” Oct. 2007. doi: 10.1080/00498250701704819.
- [7] H. Sun *et al.*, “Highly predictive and interpretable models for PAMPA permeability,” *Bioorg. Med. Chem.*, vol. 25, no. 3, pp. 1266–1276, 2017, doi: 10.1016/j.bmc.2016.12.049.
- [8] C. Jorgensen *et al.*, “Permeability Benchmarking: Guidelines for Comparing in Silico, in Vitro, and in Vivo Measurements,” Feb. 10, 2025, *American Chemical Society*. doi: 10.1021/acs.jcim.4c01815.
- [9] M. Guangli and C. Yiyu, “Predicting Caco-2 Permeability Using Support Vector Machine and Chemistry Development Kit,” 2006. [Online]. Available: <http://cdk.sf.net>
- [10] J. A. Castillo-Garit, Y. Marrero-Ponce, F. Torrens, and R. García-Domenech, “Estimation of ADME properties in drug discovery: Predicting Caco-2 cell permeability using atom-based stochastic and non-stochastic linear indices,” *J. Pharm. Sci.*, vol. 97, no. 5, pp. 1946–1976, 2008, doi: 10.1002/jps.21122.
- [11] M. Kansy, A. Avdeef, and H. Fischer, “Advances in screening for membrane permeability: High-resolution PAMPA for medicinal chemists,” Dec. 2004. doi: 10.1016/j.ddtec.2004.11.013.
- [12] H. Sun *et al.*, “Highly predictive and interpretable models for PAMPA permeability,” *Bioorg. Med. Chem.*, vol. 25, no. 3, pp. 1266–1276, 2017, doi: 10.1016/j.bmc.2016.12.049.
- [13] Deloitte, “Measuring the return from pharmaceutical innovation 2025,” 2024.
- [14] D. S. Wishart, “Improving Early Drug Discovery through ADME Modelling An Overview,” 2007.
- [15] E. H. Kerns and L. Di, “1-s2.0-S1359644603026497-main,” Apr. 2003.

- [16] K. Sugano, H. Hamada, M. Machida, and H. Ushio, "High Throughput Prediction of Oral Absorption: Improvement of the Composition of the Lipid Solution Used in Parallel Artificial Membrane Permeation Assay," *SLAS Discovery*, vol. 6, no. 3, pp. 189–196, Jun. 2001, doi: 10.1177/108705710100600309.
- [17] M. Kansy, F. Senner, and K. Gubernator, "Communications to the Editor Physicochemical High Throughput Screening: Parallel Artificial Membrane Permeation Assay in the Description of Passive Absorption Processes," 1998.
- [18] A. Adson' S *et al.*, "Quantitative Approaches To Delineate Paracellular Diffusion in Cultured Epithelial Cell Monolayers."
- [19] C. A. Lipinski, F. Lombardo, B. W. Dominy, and P. J. Feeney, "Experimental and computational approaches to estimate solubility and permeability in drug discovery and development q settings," 2001. [Online]. Available: www.elsevier.com/locate/drugdeliv
- [20] J. D. Irvine *et al.*, "MDCK (Madin-Darby canine kidney) cells: A tool for membrane permeability screening," *J. Pharm. Sci.*, vol. 88, no. 1, pp. 28–33, 1999, doi: 10.1021/js9803205.
- [21] T. Hou, J. Wang, W. Zhang, W. Wang, and X. Xu, "Recent Advances in Computational Prediction of Drug Absorption and Permeability in Drug Discovery," 2006.
- [22] I. Lesuffleur, A. Barbai, E. Dussaulx, and A. Zweibaum, "Growth Adaptation to Methotrexate of HT-29 Human Colon Carcinoma Cells Is Associated with Their Ability to Differentiate into Columnar Absorptive and Mucus-secreting Cells'," 1990. [Online]. Available: <http://aacrjournals.org/cancerres/article-pdf/50/19/6334/2440856/cr0500196334.pdf>
- [23] Chiou Win L., "Linear Correlation of the fraction oral dose absorbed of 64 drugs between humans and rats," 1998.
- [24] P. Zakeri-Milani *et al.*, "Predicting Human Intestinal Permeability using Single-pass Intestinal Perfusion in rat," 2007.
- [25] H. Sun *et al.*, "Highly predictive and interpretable models for PAMPA permeability," *Bioorg. Med. Chem.*, vol. 25, no. 3, pp. 1266–1276, 2017, doi: 10.1016/j.bmc.2016.12.049.
- [26] J. A. Castillo-Garit, Y. Marrero-Ponce, J. Escobar, F. Torrens, and R. Rotondo, "A novel approach to predict aquatic toxicity from molecular structure," *Chemosphere*, vol. 73, no. 3, pp. 415–427, Sep. 2008, doi: 10.1016/j.chemosphere.2008.05.024.
- [27] E. Directorate, "ENV/JM/MONO(2007)2 2 OECD Environment Health and Safety Publications Series on Testing and Assessment No. 69 GUIDANCE DOCUMENT ON THE VALIDATION OF (QUANTITATIVE) STRUCTURE-ACTIVITY RELATIONSHIP [(Q)SAR] MODELS," 2007.
- [28] by Gabriela Falcón Cano Supervisors and M. Ángel Cabrera Pérez Christophe Molina, "In silico prediction of biopharmaceutical properties using new modelling strategies."

- [29] R. Todeschini and V. Consonni, "Handbook of Molecular Descriptors."
- [30] H. Chipman, E. I. George, and R. E. Mcculloch, "The Practical Implementation of Bayesian Model Selection," 2001.
- [31] L. Breiman, "Random Forests," 2001.
- [32] U. Parasar, O. Baruah, D. Saikia, P. Bharali, and H. J. Mahanta, "Interpretable machine learning and graph attention network based model for predicting PAMPA permeability," *J. Mol. Graph. Model.*, vol. 138, Jul. 2025, doi: 10.1016/j.jmgm.2025.109050.
- [33] P. Baldi, S. Brunak, Y. Chauvin, C. A. F. Andersen, and H. Nielsen, "Assessing the accuracy of prediction algorithms for classification: an overview," 2000.
- [34] V. Siramshetty *et al.*, "Validating ADME QSAR Models Using Marketed Drugs," *SLAS Discovery*, vol. 26, no. 10, pp. 1326–1336, Dec. 2021, doi: 10.1177/24725552211017520.
- [35] J. Williams *et al.*, "Using in vitro ADME data for lead compound selection: An emphasis on PAMPA pH 5 permeability and oral bioavailability," Feb. 15, 2022, *Elsevier Ltd.* doi: 10.1016/j.bmc.2021.116588.
- [36] R. Kato *et al.*, "Development and validation of PAMPA-BBB QSAR model to predict brain penetration potential of novel drug candidates," *Front. Pharmacol.*, vol. 14, 2023, doi: 10.3389/fphar.2023.1291246.
- [37] R. Waheed *et al.*, "Revisiting COX-2 inhibitors for Alzheimer's disease as multitargeted ligands: Development of 4-hydrazono-pyrazolidinediones with tuned COX selectivity profile and improved cellular potency," *Eur. J. Med. Chem.*, vol. 302, Jan. 2026, doi: 10.1016/j.ejmech.2025.118261.